

Guia de inicio del proyecto

Auditor de Ventas Inteligente con VAE

Plan practico para construir en una semana una solucion basada en redes neuronales para detectar anomalías en ventas de un restaurante MiPYME ecuatoriano.

Enfoque definido: restaurante pequeño con punto de venta, cajeros, meseros, mesas, pedidos, descuentos, anulaciones y devoluciones.

1. Idea central

El proyecto consiste en construir un sistema que aprende el comportamiento normal de las transacciones de un restaurante ecuatoriano y marca como sospechosas las ventas, devoluciones, anulaciones, descuentos o cierres de cuenta que se desvían del patrón esperado.

- Problema: pérdidas silenciosas por errores de caja, descuentos fuera de política, anulaciones sospechosas, devoluciones y digitación incorrecta.
- Solución: un auditor automático que asigna un score de anomalía a cada transacción.
- RNA usada: Autoencoder Variacional, entrenado principalmente con transacciones normales.
- Resultado de negocio: priorizar las transacciones que el dueño o administrador del restaurante debe revisar.

2. Alcance MVP para una semana

El alcance debe mantenerse pequeño. La meta no es crear un POS completo, sino una herramienta que demuestre detección de anomalías, visualización clara y métricas técnicas.

- Carga de archivo CSV con ventas.
- Formulario manual para evaluar una transacción en vivo.
- Modelo VAE entrenado con datos normales.
- Tabla de resultados con semáforo: normal, baja, media y alta severidad.
- Dashboard con número de anomalías, monto en riesgo, latencia, throughput y logs.
- Prueba con mínimo 3 usuarios concurrentes.

3. Datos iniciales

Campos recomendados del CSV:

Campo	Descripción
id_transaccion	Identificador único de la venta.
fecha_hora	Fecha y hora de la transacción.
dia_semana / hora	Variables temporales para detectar patrones por horario.
cajero / mesero	Empleado que registra o atiende la transacción.
mesa / canal	Mesa, domicilio, retiro en local o app de delivery.
categoria_producto	Categoría: desayunos, almuerzos, bebidas, postres, combos, extras.
monto	Valor de la transacción.
descuento_pct	Porcentaje de descuento aplicado.
metodo_pago	Efectivo, tarjeta, transferencia u otro.
tipo_transaccion	Venta, devolución o anulación.
es_anomalia / tipo_anomalia	Etiqueta para evaluar el modelo en datos sintéticos.

Anomalías que deben inyectarse

- Descuento mayor al 50% sin justificación.
- Venta fuera del horario normal del restaurante.
- Anulación o devolución de monto alto o muy frecuente.
- Monto diez veces mayor al ticket promedio del restaurante.
- Monto negativo, cero o inconsistente.
- Venta con descuento alto y pago en efectivo.
- Cajero o mesero con tasa de anulaciones inusualmente alta.

4. Arquitectura de la solución

Componente	Responsabilidad
Preprocesamiento	Normalizar montos, codificar categorías, convertir hora a seno/coseno y preparar el vector de entrada.
VAE	Encoder denso, espacio latente con μ y σ , reparametrización y decoder para reconstruir la transacción.
Score de anomalía	Error de reconstrucción total, ponderado si se desea dar más peso a monto y descuento.
Umbral	Percentil 95 del error en validación normal, ajustable por negocio.
Backend	FastAPI con endpoints para transacción individual, batch CSV, métricas y logs.
Frontend	Streamlit para carga de CSV, formulario manual, tabla, dashboard y descarga de resultados.

5. Tecnologías a utilizar

Todas las herramientas propuestas son gratuitas y suficientes para el MVP. La prioridad es terminar un flujo completo: generar datos, entrenar, evaluar, exponer API, visualizar y medir.

Parte	Tecnología	Uso concreto
Lenguaje base	Python	Implementar generación de datos, preprocesamiento, entrenamiento, backend y app.
Datos sintéticos	pandas, NumPy	Crear ventas normales y anomalías de restaurante en CSV.
Preprocesamiento	scikit-learn, joblib	One-hot encoding, normalización, división train/test y guardado del preprocesador.
RNA / VAE	PyTorch	Construir encoder, reparametrización, decoder, función de pérdida y entrenamiento.
Métricas ML	scikit-learn	Precision, recall, F1, matriz de confusión, ROC-AUC si aplica.
Backend	FastAPI, Uvicorn, Pydantic	Endpoints /predict, /batch y /metrics; validación de transacciones.
Frontend	Streamlit, Plotly	Carga CSV, formulario manual, tabla con semáforo y dashboard interactivo.
Logs y recursos	logging, time, psutil	Registrar predicciones, latencia, throughput, CPU y RAM.
Concurrencia	Locust o 3 sesiones Streamlit	Demostrar tres usuarios usando la app en paralelo.

Parte	Tecnologia	Uso concreto
Despliegue	Hugging Face Spaces o Render	Publicar el prototipo si hay tiempo; si no, demo local estable.
Presentacion	PowerPoint, Google Slides o Canva	PPT con problema, arquitectura, metricas, demo, negocio, riesgos y pricing.
Control de versiones	Git	Coordinar trabajo del grupo y mantener cambios ordenados.

6. Division del trabajo para 6 personas

Persona	Responsabilidad principal	Entrega minima
Martín Dávalos	Datos y contexto del restaurante	CSV sintetico, reglas del negocio y tipos de anomalía.
2	Preprocesamiento	Pipeline que transforma CSV a tensores listos para el VAE.
3	Modelo VAE	Entrenamiento, guardado del modelo y error de reconstruccion.
4	Evaluacion y umbrales	Precision, recall, F1, umbral, severidad y monto en riesgo.
5	Backend y metricas tecnicas	Endpoints, logs, latencia, throughput y pruebas concurrentes.
6	Frontend, demo y PPT	Streamlit funcional, guion de demo y diapositivas.

7. Plan de 5 dias

Dia	Objetivo	Resultado esperado
1	Definir negocio y generar datos.	Dataset normal + anomalías documentadas.
2	Preprocesar y entrenar primer VAE.	Modelo que separa parcialmente normal vs anomalo.
3	Calcular score, umbral y backend.	API evaluando transacciones individuales y por lote.
4	Construir frontend.	Carga CSV, formulario, tabla con semaforo y dashboard.
5	Probar, medir y preparar presentacion.	Demo estable, metricas, logs y PPT terminada.

8. Estructura sugerida del repositorio

```

RNA_IA/
data/
ventas_restaurante_sinteticas.csv
models/
vae_model.pt
preprocessor.pkl
src/
generate_data.py
preprocess.py
train_vae.py
evaluate.py
api.py
app_streamlit.py
requirements.txt
reports/
metricas_demo.csv
logs_predicciones.csv
output/pdf/
Guia_Inicio_Auditor_Ventas_VAE.pdf

```

9. Metricas para presentar

- Calidad del modelo: precision, recall, F1 y matriz de confusion sobre anomalías conocidas.
- Score de anomalía: promedio normal vs promedio anomalo.
- Latencia: tiempo promedio para evaluar una transaccion individual.
- Throughput: transacciones por segundo en procesamiento batch.
- Recursos: CPU y RAM durante inferencia.
- Estabilidad: 3 usuarios simultaneos usando la app sin errores.
- Negocio: monto total en riesgo detectado y numero de casos priorizados.

10. Modelo de negocio recomendado

El modelo mas facil de defender para MiPYMEs es una suscripcion mensual por volumen de transacciones. Es coherente porque el problema ocurre todos los dias, el sistema requiere mantenimiento, recalibracion de umbrales y soporte, y el cliente evita una inversion inicial alta.

Plan	Uso sugerido	Precio referencial
Micro	Hasta 2.000 transacciones/mes.	USD 9,99 - 14,99/mes.
PYME	Hasta 10.000 transacciones/mes.	USD 24,99 - 39,99/mes.
Pro	Mayor volumen, soporte y reportes.	USD 49,99+/mes.

11. Riesgos y limitaciones

- Los datos sinteticos no capturan toda la variabilidad de un negocio real.
- El sistema sugiere revision humana; no debe bloquear ventas automaticamente.
- Puede haber falsos positivos en ventas legitimas pero poco frecuentes.

- Cada negocio necesita recalibrar el umbral de anomalía.
- Trabajo futuro: entrenar con datos reales anonimizados y agregar explicaciones por campo.

12. Primeros pasos inmediatos

- Fijar el tipo de restaurante: almuerzos, cafetería, comida rápida o restaurante familiar.
- Definir horarios, cajeros, meseros, mesas/canales, categorías y políticas de descuento.
- Generar 5.000 a 20.000 transacciones sintéticas.
- Separar normales para entrenamiento y anomalías para validación.
- Construir primero el pipeline completo, aunque el modelo inicial sea pequeño.